QCEX

Quantum Commodity Exchange

Fundamentos Teóricos e Implementación

Modelo Schwartz-Smith de Dos Factores · Filtro de Kalman
Volatilidad Estocástica SABR · Valoración Black-76
VaR/CVaR Histórico · Pruebas de Estrés

Autor	**Pablo M. Paniagua**
Proyecto	QCEX — Quantum Commodity Exchange
Materias primas	Cacao (ICE CC1) · Gas Natural TTF · Uranio U3O8
Referencias	Schwartz (1997) · Schwartz & Smith (2000) Hagan et al. (2002) · Black (1976)
Tecnología	Python 3.11 · NumPy · SciPy · Streamlit · Plotly

Contents

1 Introducción y Motivación **3**
1.1 Selección de Materias Primas . . . 3
1.2 Arquitectura del Sistema . . . 3

2 Marco Teórico: Dinámica de los Precios de Materias Primas **3**
2.1 La Teoría del Almacenamiento . . . 3
2.2 Hechos Estilizados . . . 4

3 El Modelo Schwartz-Smith de Dos Factores **4**
3.1 Motivación . . . 4
3.2 Dinámica bajo la Medida Real $\mathbb{P}$ . . . 4
3.3 Medida Neutral al Riesgo $\mathbb{Q}$ . . . 4
3.4 Fórmula de Valoración de Futuros . . . 5
3.5 Forma Estado-Espacio . . . 5

4 Filtro de Kalman y Calibración MLE **5**
4.1 Recursion del Filtro de Kalman . . . 5
4.2 Log-Verosimilitud y MLE . . . 5

5 Simulación Monte Carlo **6**

6 Modelo Black-76 para Opciones sobre Futuros **6**

7 Modelo de Volatilidad Estocástica SABR **6**
7.1 Dinámica del Modelo . . . 7
7.2 Aproximación de Hagan (2002) . . . 7
7.3 Calibración . . . 7

8 Analítica de Riesgo **8**
8.1 Valor en Riesgo . . . 8
8.2 Pruebas de Estrés . . . 8
8.3 Cono de Volatilidad . . . 8

9 Arquitectura e Implementación **8**

10 Análisis Específico por Commodity **9**
10.1 Cacao . . . 9
10.2 Gas Natural TTF . . . 9
10.3 Uranio U3O8 . . . 9

11 Indicadores Meteorológicos e Integración en el Modelo **9**
11.1 Motivación: el clima como factor de oferta y demanda . . . 9
11.2 Cacao: ENSO y las lluvias de África Occidental . . . 10
11.2.1 Mecanismo de transmisión . . . 10
11.2.2 Indicadores implementados . . . 10
11.2.3 Integración en el modelo de precios . . . 10
11.3 Gas Natural TTF: Grados-Día de Calefacción (HDD) . . . 10
11.3.1 Mecanismo de transmisión . . . 10
11.3.2 Heating Degree Days (HDD) . . . 11

11.3.3 Estacionalidad sinusoidal 11
11.3.4 Indicadores implementados 11
11.4 Uranio U3O8: Sin driver meteorológico directo 11
11.5 Arquitectura del módulo `data/weather.py` 12

12 Motor de Backtesting **12**
12.1 Motivación y filosofía de diseño 12
12.2 Estrategias implementadas 12
12.2.1 Trend Following — Cruce de EMAs 12
12.2.2 Mean Reversion — Bandas de Bollinger 12
12.2.3 Momentum 13
12.2.4 Weather-Driven — Estacional 13
12.2.5 Vol Breakout 13
12.2.6 Combinada — Ensemble de igual peso 13
12.3 Métricas de rendimiento 13
12.4 Resultados empíricos: Gas Natural TTF 13
12.5 Advertencias 14

1. Introducción y Motivación

Este documento presenta la derivación teórica completa del sistema **QCEX** (*Quantitative Risk & Commodity Lab Engine*), un motor cuantitativo de producción para la valoración, calibración y gestión del riesgo de derivados sobre materias primas físicas. El proyecto está estructurado deliberadamente en torno a commodities con alta riqueza analítica pero escasa cobertura en portfolios cuantitativos estándar.

1.1. Selección de Materias Primas

Commodity	Referencia	Unidad	Característica analítica clave
Cacao	ICE Futures CC1	USD/MT	Concentración geográfica, correlación ENSO, crisis vol 2023-
Gas TTF	ICE TTF / NG	EUR/MWh	Estacionalidad fuerte, riesgo geopolítico, flujos GNL
Uranio U3O8	OTC / URA	USD/lb	Mercado OTC, política nuclear, smile escaso

Table 1: Materias primas cubiertas y sus características analíticas

1.2. Arquitectura del Sistema

El sistema se estructura en cuatro capas modulares:

1. **Capa de datos** (`data/fetcher.py`): yfinance como fuente primaria con fallback sintético de proceso OU.
2. **Capa de modelos** (`models/`): Schwartz-Smith dos factores con Filtro de Kalman; SABR con aproximación de Hagan; Black-76 con Greeks completos.
3. **Capa analítica** (`analytics/risk.py`): VaR y CVaR histórico y paramétrico, cono de volatilidad, pruebas de estrés, drawdown.
4. **Capa de presentación** (`app/`): Aplicación Streamlit de cuatro páginas con Plotly, datos en tiempo real y calibración interactiva.

2. Marco Teórico: Dinámica de los Precios de Materias Primas

2.1. La Teoría del Almacenamiento

La relación fundamental entre precios al contado y futuros fue formalizada por **Working (1949)** mediante la *teoría del almacenamiento*:

$$F(t,T) = S_t \cdot e^{(r+u-y)(T-t)} \tag{1}$$

donde r es el tipo libre de riesgo, u el coste de almacenamiento físico anualizado, e y el **rendimiento de conveniencia** (*convenience yield*): el beneficio implícito de poseer el commodity físico. El rendimiento de conveniencia se extrae por *bootstrapping*:

$$y(t,T) = r + u - \frac{1}{\tau}\ln\left(\frac{F(t,T)}{S_t}\right) \tag{2}$$

Definición 2.1 (Estructura del mercado). *Cuando $y > r + u$: **backwardation** ($F < S$), oferta física escasa. Cuando $y < r + u$: **contango** ($F > S$), costes de almacenamiento dominantes.*

2.2. Hechos Estilizados

H1. Reversión a la media: los precios tienden a un equilibrio de largo plazo determinado por los costes de producción.

H2. Estacionalidad: oferta y demanda son periódicas.

H3. Efectos de inventario: inventarios bajos amplifican la volatilidad y la backwardation (Fama y French, 1987).

H4. Asimetría negativa: las disrupciones de oferta causan spikes al alza. Colas izquierdas más gruesas que la normal.

H5. Volatilidad estocástica: smiles de vol pronunciados; modelos más allá de Black-Scholes son necesarios.

H6. Correlación imperfecta en la curva: futuros de corto y largo plazo no están perfectamente correlacionados.

3. El Modelo Schwartz-Smith de Dos Factores

3.1. Motivación

Schwartz y Smith (2000) demostraron que un único factor latente implica correlación perfecta en toda la curva de futuros, hipótesis rechazada en los datos. El modelo de dos factores separa:

$$\ln S_t = \chi_t + \xi_t \tag{3}$$

- χ_t: **factor de corto plazo** (Ornstein-Uhlenbeck) — desviaciones transitorias del equilibrio.
- ξ_t: **factor de largo plazo** (GBM con drift) — nivel de precio de equilibrio.

3.2. Dinámica bajo la Medida Real $\mathbb{P}$

$$\mathrm{d}\chi_t = -\kappa\,\chi_t\,\mathrm{d}t + \sigma_\chi\,\mathrm{d}W_\chi^{\mathbb{P}} \tag{4}$$

$$\mathrm{d}\xi_t = \mu_\xi\,\mathrm{d}t + \sigma_\xi\,\mathrm{d}W_\xi^{\mathbb{P}} \tag{5}$$

$$\mathrm{d}W_\chi^{\mathbb{P}}\,\mathrm{d}W_\xi^{\mathbb{P}} = \rho\,\mathrm{d}t \tag{6}$$

La **semivida** del factor de corto plazo es $h = \ln 2/\kappa$:

- **Cacao** ($\kappa = 0{,}80$): semivida $\approx$ 10,4 meses.
- **Gas TTF** ($\kappa = 2{,}10$): semivida $\approx$ 4,0 meses.
- **Uranio** ($\kappa = 0{,}30$): semivida $\approx$ 27,6 meses.

3.3. Medida Neutral al Riesgo $\mathbb{Q}$

Introduciendo precios de mercado del riesgo λ_χ y λ_ξ (Girsanov):

$$\mathrm{d}\chi_t = \left(-\kappa\chi_t - \lambda_\chi\right)\,\mathrm{d}t + \sigma_\chi\,\mathrm{d}W_\chi^{\mathbb{Q}} \tag{7}$$

$$\mathrm{d}\xi_t = \left(\mu_\xi - \lambda_\xi\right)\,\mathrm{d}t + \sigma_\xi\,\mathrm{d}W_\xi^{\mathbb{Q}} \tag{8}$$

3.4. Fórmula de Valoración de Futuros

Teorema 3.1 (Precio de futuros Schwartz-Smith).

$$\ln F(t,T) = e^{-\kappa\tau}\chi_t + \xi_t + A(\tau) \tag{9}$$

donde $\tau = T - t$ *y:*

$$A(\tau) = (\mu_\xi - \lambda_\xi)\tau - \frac{1-e^{-\kappa\tau}}{\kappa}\lambda_\chi + \frac{\sigma_\xi^2\tau}{2} + \frac{\sigma_\chi^2(1-e^{-2\kappa\tau})}{4\kappa} + \frac{\rho\sigma_\chi\sigma_\xi(1-e^{-\kappa\tau})}{\kappa} \tag{10}$$

Cuando $\tau \to \infty$: $\ln F \to \xi_t + A(\tau)$ — los futuros de largo plazo dependen *solo* del factor permanente ξ_t.

3.5. Forma Estado-Espacio

Vector de estado $\mathbf{x}_t = (\chi_t, \xi_t)^\top$. Discretización exacta:

$$\mathbf{x}_t = \mathbf{F}\,\mathbf{x}_{t-1} + \boldsymbol{\eta}_t, \quad \boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}) \tag{11}$$

$$\mathbf{F} = \begin{pmatrix} e^{-\kappa\Delta t} & 0 \\ 0 & 1 \end{pmatrix}, \quad Q_{11} = \frac{\sigma_\chi^2}{2\kappa}(1-e^{-2\kappa\Delta t}), \quad Q_{22} = \sigma_\xi^2\Delta t, \quad Q_{12} = \frac{\rho\sigma_\chi\sigma_\xi}{\kappa}(1-e^{-\kappa\Delta t}) \tag{12}$$

Ecuación de observación (n contratos de futuros):

$$\mathbf{y}_t = \mathbf{H}\,\mathbf{x}_t + \mathbf{d} + \boldsymbol{\varepsilon}_t, \quad \mathbf{H}_{ij} = \begin{cases} e^{-\kappa\tau_i} & j=1 \\ 1 & j=2 \end{cases}, \quad d_i = A(\tau_i) \tag{13}$$

4. Filtro de Kalman y Calibración MLE

4.1. Recursion del Filtro de Kalman

Predicción:

$$\hat{\mathbf{x}}_{t|t-1} = \mathbf{F}\,\hat{\mathbf{x}}_{t-1|t-1} \tag{14}$$

$$\mathbf{P}_{t|t-1} = \mathbf{F}\,\mathbf{P}_{t-1|t-1}\,\mathbf{F}^\top + \mathbf{Q} \tag{15}$$

Innovación: $\mathbf{v}_t = \mathbf{y}_t - \mathbf{H}\hat{\mathbf{x}}_{t|t-1} - \mathbf{d}, \quad \mathbf{S}_t = \mathbf{H}\mathbf{P}_{t|t-1}\mathbf{H}^\top + s^2\mathbf{I}$
Actualización:

$$\mathbf{K}_t = \mathbf{P}_{t|t-1}\mathbf{H}^\top\mathbf{S}_t^{-1} \tag{16}$$

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{K}_t\mathbf{v}_t \tag{17}$$

$$\mathbf{P}_{t|t} = (\mathbf{I} - \mathbf{K}_t\mathbf{H})\mathbf{P}_{t|t-1} \tag{18}$$

4.2. Log-Verosimilitud y MLE

$$\ell(\boldsymbol{\theta}) = -\frac{1}{2}\sum_{t=1}^{T}\Big[\ln|\mathbf{S}_t| + \mathbf{v}_t^\top\mathbf{S}_t^{-1}\mathbf{v}_t + n\ln(2\pi)\Big] \tag{19}$$

Maximizado via **L-BFGS-B** con múltiples reinicios aleatorios para mitigar óptimos locales. Los resultados de validación muestran errores medios de extracción de estados de $|\hat{\chi}_t - \chi_t| \approx 0{,}016$ y $|\hat{\xi}_t - \xi_t| \approx 0{,}010$.

5. Simulación Monte Carlo

Dados los parámetros calibrados y los estados filtrados $(\hat{\chi}_T, \hat{\xi}_T)$, las trayectorias futuras se simulan bajo $\mathbb{P}$ con discretización exacta del OU:

$$\chi_t = \chi_{t-1} e^{-\kappa \Delta t} + \sigma_\chi \sqrt{\frac{1 - e^{-2\kappa \Delta t}}{2\kappa}}\, Z_\chi \tag{20}$$

$$\xi_t = \xi_{t-1} + \mu_\xi \Delta t + \sigma_\xi \sqrt{\Delta t}\, Z_\xi \tag{21}$$

con $(Z_\chi, Z_\xi)^\top = \mathbf{LZ}$ generados por descomposición de Cholesky de la matriz de correlación. Precio de opción call por Monte Carlo:

$$C_{\mathrm{MC}} = e^{-rT} \frac{1}{N} \sum_{i=1}^{N} \max(S_T^{(i)} - K, 0), \quad \widehat{\mathrm{SE}} = e^{-rT} \frac{\hat{\sigma}_{\mathrm{payoff}}}{\sqrt{N}} \tag{22}$$

Con $N = 50.000$ trayectorias, el error estándar es del orden de $\pm 0{,}0004$.

6. Modelo Black-76 para Opciones sobre Futuros

Bajo $\mathbb{Q}$: $\mathrm{d}F = \sigma F \, \mathrm{d}W^{\mathbb{Q}}$. Fórmulas de valoración:

$$C = e^{-r\tau} \left[F\, N(d_1) - K\, N(d_2) \right] \tag{23}$$

$$P = e^{-r\tau} \left[K\, N(-d_2) - F\, N(-d_1) \right] \tag{24}$$

$$d_1 = \frac{\ln(F/K) + \frac{1}{2}\sigma^2 \tau}{\sigma \sqrt{\tau}}, \quad d_2 = d_1 - \sigma \sqrt{\tau}$$

Greek	Fórmula (call)	Significado financiero
Δ	$e^{-r\tau} N(d_1)$	Sensibilidad al forward
Γ	$e^{-r\tau} \phi(d_1) / (F\sigma\sqrt{\tau})$	Convexidad respecto a F
ν	$F e^{-r\tau} \phi(d_1) \sqrt{\tau}$	Sensibilidad a la volatilidad
Θ	$-F e^{-r\tau} \phi(d_1) \sigma / (2\sqrt{\tau}) - rK e^{-r\tau} N(d_2)$	Decaimiento temporal
Vanna	$\partial^2 V / \partial F \partial \sigma$	Mixta F-vol; clave en barreras
Volga	$\partial^2 V / \partial \sigma^2$	Convexidad de vol; riesgo del smile

Table 2: Greeks de Black-76 para opciones de compra. $\phi(\cdot)$: densidad normal estándar.

7. Modelo de Volatilidad Estocástica SABR

7.1. Dinámica del Modelo

Black-76 produce superficie de vol plana. El modelo SABR (Hagan et al., 2002) captura el smile y el sesgo observados en opciones sobre commodities:

$$\mathrm{d}F = \sigma\, F^{\beta}\, \mathrm{d}W_1 \tag{25}$$
$$\mathrm{d}\sigma = \alpha\, \sigma\, \mathrm{d}W_2 \tag{26}$$
$$\mathrm{d}W_1\, \mathrm{d}W_2 = \rho\, \mathrm{d}t \tag{27}$$

Par.	Rol	Intuición en commodities
α	Nivel de vol	Escala el smile; calibra a vol ATM
$\beta = 0{,}5$	Elasticidad CEV	Estándar en commodities
$\rho < 0$	Generador del sesgo	Puts OTM caras; riesgo de oferta
ν	Vol de la vol	Curvatura del smile; alto en energía

Table 3: Parámetros SABR e interpretación económica

7.2. Aproximación de Hagan (2002)

$$\sigma_B(K,T) \approx \frac{\alpha}{D(K)} \cdot \frac{z}{\chi(z)} \cdot C(T) \tag{28}$$

$$D(K) = (FK)^{(1-\beta)/2}\left[1 + \tfrac{(1-\beta)^2}{24}\ln^2\tfrac{F}{K} + \tfrac{(1-\beta)^4}{1920}\ln^4\tfrac{F}{K}\right] \tag{29}$$
$$z = \tfrac{\nu}{\alpha}(FK)^{(1-\beta)/2}\ln\tfrac{F}{K} \tag{30}$$
$$\chi(z) = \ln\left[\tfrac{\sqrt{1-2\rho z+z^2}+z-\rho}{1-\rho}\right] \tag{31}$$
$$C(T) = 1 + T\left[\tfrac{(1-\beta)^2\alpha^2}{24(FK)^{1-\beta}} + \tfrac{\rho\beta\nu\alpha}{4(FK)^{(1-\beta)/2}} + \tfrac{\nu^2(2-3\rho^2)}{24}\right] \tag{32}$$

Interpretación del sesgo: $\partial\sigma_B/\partial K|_{K=F} \approx -\rho\nu/[2F^{(1-\beta)/2}]$. Un ρ negativo induce sesgo negativo: el mercado asigna mayor vol implícita a strikes a la baja (puts OTM caras), patrón dominante en commodities con riesgo de concentración de oferta.

Curvatura del smile: $\partial^2\sigma_B/\partial K^2|_{K=F} \propto \nu^2$. Un ν alto (gas TTF: $\nu = 0{,}85$) produce alas pronunciadas; bajo (uranio: $\nu = 0{,}42$) perfil más plano.

7.3. Calibración

Con $\beta = 0{,}5$ fijo, se calibra (α, ρ, ν) por mínimos cuadrados ponderados:

$$(\hat{\alpha}, \hat{\rho}, \hat{\nu}) = \arg\min_{\alpha,\rho,\nu} \sum_{i=1}^{n} w_i \left[\sigma_B(K_i, T;\, \alpha, \rho, \nu) - \sigma_i^{\mathrm{mkt}}\right]^2 \tag{33}$$

Resuelto mediante L-BFGS-B multi-inicio por segmento de vencimiento. RMSE de calibración (Cacao, T=6M, 11 strikes): **33,6 pb**.

8. Analítica de Riesgo

8.1. Valor en Riesgo

Definición 8.1 (VaR Histórico). *$VaR_{p,h} = -Q_p\left(\{r_i\sqrt{h}\}\right)$ donde $r_i = \ln(S_i/S_{i-1})$ son los retornos log diarios.*

Definición 8.2 (CVaR / Pérdida Esperada). *$CVaR_{p,h} = -\mathbb{E}[r\sqrt{h} \mid r\sqrt{h} < -VaR_{p,h}]$. Medida de riesgo coherente (Artzner et al., 1999); estándar regulatorio bajo FRTB (Basilea III/IV).*

Observación 8.1. *Los retornos de commodities tienen exceso de curtosis. El VaR Gaussiano* subestima *systemáticamente el riesgo real. Se prefiere el VaR histórico.*

8.2. Pruebas de Estrés

Commodity	Escenario	Shock	Mecanismo
Cacao	El Niño severo	−45%	Sequía en África Occidental
Cacao	Enfermedad fúngica	−35%	*Swollen shoot*; 30% de cosecha
Gas TTF	Invierno frío extremo	+80%	HDD +40%; demanda calefacción
Gas TTF	Resolución conflicto	−50%	Gasoductos rusos; exceso oferta
Uranio	Recorte Kazatomprom	+50%	−20% producción; 43% mundial
Uranio	Accidente nuclear	−40%	Nivel 4–5; parada reactores

Table 4: Escenarios de estrés seleccionados

8.3. Cono de Volatilidad

$\hat{\sigma}_w(t) = \sqrt{252}\,\hat{\sigma}(\{r_i\}_{i=t-w+1}^{t})$ para ventanas $w \in \{5, 10, 21, 63, 126, 252\}$ días. Los percentiles empíricos $\{P_{10}, \ldots, P_{90}\}$ permiten identificar si la volatilidad actual es históricamente barata o cara.

9. Arquitectura e Implementación

Módulo	Funciones clave	Dependencias
`models/schwartz_smith.py`	`kalman_filter`, `calibrate`, `simulate_paths`	NumPy, SciPy
`models/sabr.py`	`SABRModel`, `sabr_implied_vol`, `sabr_greeks`	NumPy, SciPy
`analytics/risk.py`	`historical_var`, `stress_table`, `vol_cone`	NumPy, Pandas
`data/fetcher.py`	`fetch_prices`, `build_term_structure`	yfinance, Pandas
`Home.py`	Punto de entrada Streamlit	Streamlit, Plotly

Table 5: Estructura de módulos y componentes clave

Operación	Tiempo (s)	RMSE	Método
Filtro de Kalman (T=260, n=6)	$< 0{,}01$	—	Recursión exacta
MLE Schwartz-Smith (5 reinicios)	≈ 48	—	L-BFGS-B
Calibración SABR (11 strikes)	0,20	33,6 pb	L-BFGS-B multi-inicio
Vol implícita Black-76	$< 0{,}001$	$< 10^{-8}$	Newton-Raphson
MC opción (50.000 paths)	≈ 2	$\pm 0{,}0004$	Cholesky correlado

Table 6: Benchmarks de rendimiento computacional

10. Análisis Específico por Commodity

10.1. Cacao

El mercado mundial del cacao presenta concentración geográfica extrema: Costa de Marfil y Ghana producen conjuntamente el 65% de la producción mundial. El episodio El Niño de 2023–24 desencadenó una crisis de oferta que elevó los precios de $\approx$ \$3.000/MT a más de \$12.000/MT, produciendo la alta volatilidad calibrada $\sigma_\chi = 0{,}38$ y el fuerte sesgo SABR negativo $\rho = -0{,}45$.

10.2. Gas Natural TTF

Tras la crisis energética de 2022, la volatilidad del TTF se desplazó a un régimen estructuralmente más alto ($\nu = 0{,}85$). La estacionalidad se modela como: $\text{Estacional}(m) = 1 + 0{,}35\cos((m-1) \cdot 2\pi/12)$, generando la prima de invierno en la curva de futuros. El alto $\kappa = 2{,}10$ (semivida ≈ 4 meses) refleja la rápida sustitución de déficits por GNL.

10.3. Uranio U3O8

Mercado OTC sin cotización en bolsa organizada. El ETF URA de Sprott se usa como proxy. Con $\kappa = 0{,}30$ (semivida ≈ 28 meses), los precios responden lentamente. La apreciación 2021–24 de $\approx$ \$30/lb a $>$ \$100/lb refleja: (a) interés renovado en energía nuclear post-2022, (b) recortes de Kazatomprom (43% producción mundial), y (c) demanda financiera vía fondos físicos de uranio.

11. Indicadores Meteorológicos e Integración en el Modelo

11.1. Motivación: el clima como factor de oferta y demanda

Los precios de las materias primas físicas están directamente condicionados por variables meteorológicas. A diferencia de los activos financieros, cuya oferta y demanda se determinan principalmente por variables macroeconómicas, los commodities físicos tienen ciclos de producción y consumo con una fuerte dependencia climática. El sistema QCEX integra datos meteorológicos reales procedentes de la API abierta **Open-Meteo** (`archive-api.open-meteo.com`), que proporciona datos históricos diarios de temperatura y precipitación sin necesidad de clave de acceso. Cuando la conexión no está disponible, el sistema genera datos sintéticos mediante funciones sinusoidales calibradas a los patrones estacionales históricos de cada zona geográfica.

11.2. Cacao: ENSO y las lluvias de África Occidental

11.2.1. Mecanismo de transmisión

La producción mundial de cacao se concentra en una franja tropical estrecha. Costa de Marfil y Ghana producen conjuntamente el 65% de la oferta global, lo que hace al mercado estructuralmente vulnerable a cualquier perturbación meteorológica en esa región.

El principal driver climático es el fenómeno **ENSO** (*El Niño-Southern Oscillation*). Los episodios de *El Niño* desplazan la zona de convergencia intertropical, reduciendo las precipitaciones en África Occidental durante los meses críticos de floración y formación del fruto (febrero–abril). La cadena causal es:

El Niño → Reducción de lluvias en Ghana/Costa de Marfil → Estrés hídrico en plantaciones → Caída del rendimiento por árbol → Menor oferta → Subida de precios

El episodio de 2023–24 ilustra perfectamente este mecanismo: el Niño más severo desde 1998 provocó una caída de la producción del 25% y elevó los precios desde \$3.000/MT hasta más de \$12.000/MT en menos de doce meses.

11.2.2. Indicadores implementados

El módulo `data/weather.py` calcula los siguientes indicadores para la ubicación de referencia (Abidján, 5.35°N / 4.00°W):

Indicador	Cálculo	Señal alcista para precio
Precipitación 30d	Media de lluvia diaria (mm)	$<$ media histórica
Días secos (30d)	Días con lluvia $< 0{,}5$ mm	> 15 días
Anomalía térmica	$\bar{T}_{30d} - \bar{T}_{\text{hist}}$	$> +1{,}5$°C
Proxy ENSO	$(\bar{P}_{30d} - \bar{P}_{\text{hist}})/\bar{P}_{\text{hist}}$	$< -0{,}20$

Table 7: Indicadores meteorológicos para Cacao

11.2.3. Integración en el modelo de precios

Formalmente, los indicadores meteorológicos pueden incorporarse como regresores en el factor de largo plazo ξ_t del modelo Schwartz-Smith. La extensión propuesta es:

$$d\xi_t = \left(\mu_\xi + \beta_{\text{ENSO}} \cdot \text{ENSO}_t\right) dt + \sigma_\xi \, dW_\xi \tag{34}$$

donde ENSO_t es el índice proxy calculado a partir de la anomalía de precipitación. Un $\beta_{\text{ENSO}} < 0$ implica que períodos secos (ENSO negativo) generan presión alcista sobre el nivel de equilibrio del precio.

11.3. Gas Natural TTF: Grados-Día de Calefacción (HDD)

11.3.1. Mecanismo de transmisión

El gas natural es el único commodity del sistema con un driver de **demanda** meteorológica dominante (a diferencia del cacao, cuyo driver es de oferta). La demanda de calefacción en Europa está directamente correlacionada con la temperatura exterior. La ubicación de referencia es Berlín (52.52°N / 13.40°E), representativa del mercado centroeuropeo que determina los precios TTF.

11.3.2. Heating Degree Days (HDD)

Los **Grados-Día de Calefacción** son la métrica estándar de la industria energética para cuantificar la demanda térmica:

$$\mathrm{HDD}_d = \max\big(T_{\text{base}} - T_d,\ 0\big) \tag{35}$$

donde $T_{\text{base}} = 15{,}5°\mathrm{C}$ es la temperatura a partir de la cual se activa la calefacción, y T_d es la temperatura media del día d. El HDD acumulado en 30 días:

$$\mathrm{HDD}_{30} = \sum_{d=t-29}^{t} \max(15{,}5 - T_d,\ 0) \tag{36}$$

La anomalía respecto a la media histórica determina si el invierno es más frío o más suave de lo habitual, generando respectivamente presión alcista o bajista sobre el TTF.

11.3.3. Estacionalidad sinusoidal

Cuando los datos reales no están disponibles, el sistema aproxima la temperatura diaria en Berlín con la función:

$$T(m) = 12 + 10\cos\left(\frac{(m-1)\cdot 2\pi}{12}\right) + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0,4) \tag{37}$$

Esta función sinusoidal captura el ciclo anual: temperatura mínima en enero ($T \approx 2°\mathrm{C}$) y máxima en julio ($T \approx 22°\mathrm{C}$), con volatilidad diaria de 2°C. **No es un pronóstico**, sino un fallback para garantizar que la aplicación funcione sin conexión a internet.

11.3.4. Indicadores implementados

Indicador	Cálculo	Señal alcista para TTF
HDD 30 días	$\sum_d \max(15{,}5 - T_d, 0)$	$>$ media histórica
Anomalía HDD (%)	$(HDD_{30} - \overline{HDD})/\overline{HDD}$	$> +15\%$
Temperatura media 7d	$\bar{T}_{7d}$	$< 0°\mathrm{C}$
Días bajo 0°C (30d)	Días con $T_d < 0$	$>$ 15 días

Table 8: Indicadores meteorológicos para Gas Natural TTF

11.4. Uranio U3O8: Sin driver meteorológico directo

El uranio es el único commodity del sistema sin dependencia meteorológica directa. Sus precios están determinados por:

1. **Política nuclear**: número de reactores en operación y construcción
2. **Concentración de oferta**: Kazajistán (Kazatomprom) controla el 43% de la producción mundial
3. **Demanda financiera**: fondos físicos como el Sprott Uranium Trust
4. **Ciclos de contratos a largo plazo**: las utilities firman contratos de suministro a 5–10 años, desconectando el precio spot del equilibrio de corto plazo

El panel de indicadores para uranio en QCEX sustituye las variables meteorológicas por indicadores de política energética y estructura de mercado, que son los drivers reales.

11.5. Arquitectura del módulo `data/weather.py`

El módulo sigue una arquitectura de dos niveles:

N1. Datos reales: petición HTTP a la API Open-Meteo con timeout de 5 segundos. Si la respuesta es válida, se calculan los indicadores sobre datos históricos reales.

N2. Fallback sintético: si la petición falla (sin internet, timeout, etc.), se generan datos mediante el proceso estocástico estacional descrito anteriormente. El panel muestra la etiqueta `SYNTHETIC` en lugar de `OPEN-METEO`.

Este diseño garantiza que la aplicación **siempre funciona**, tanto en entornos con conexión (datos reales) como en demostraciones offline (datos sintéticos).

12. Motor de Backtesting

12.1. Motivación y filosofía de diseño

Un modelo de valoración sin validación empírica está incompleto. El motor de backtesting de QCEX evalúa si estrategias sistemáticas basadas en los modelos anteriores generan retornos ajustados al riesgo positivos sobre datos históricos reales.

El motor (`analytics/backtest.py`) sigue tres principios fundamentales:

1. **Sin sesgo de anticipación**: todas las señales se desplazan un día antes de calcular retornos. La estrategia nunca usa información del futuro.
2. **Costes de transacción**: coste unidireccional configurable (por defecto 10 pb) descontado en cada cambio de posición.
3. **Benchmark**: todas las estrategias se comparan contra comprar y mantener.

12.2. Estrategias implementadas

12.2.1. Trend Following — Cruce de EMAs

$$\text{Señal}_t = \begin{cases} +1 & \text{si } \text{EMA}_{20}(P_t) > \text{EMA}_{60}(P_t) \\ -1 & \text{si } \text{EMA}_{20}(P_t) < \text{EMA}_{60}(P_t) \end{cases} \tag{38}$$

La EMA rápida (20 días) cruzando por encima de la lenta (60 días) activa una posición larga. Funciona bien en commodities con tendencias estructurales persistentes.

12.2.2. Mean Reversion — Bandas de Bollinger

$$\text{Señal}_t = \begin{cases} +1 & \text{si } P_t < \mu_t - 1{,}5\,\sigma_t \quad \text{(sobrevendido)} \\ -1 & \text{si } P_t > \mu_t + 1{,}5\,\sigma_t \quad \text{(sobrecomprado)} \\ 0 & \text{en otro caso} \end{cases} \tag{39}$$

Estrategia contraria: compra cuando el precio cae demasiado, vende cuando sube demasiado. Especialmente efectiva en commodities con fuerte reversión a la media como el gas natural.

12.2.3. Momentum

$\text{Señal}_t = \text{signo}(P_t - P_{t-21})$ — largo si el precio subió el último mes, corto si bajó.

12.2.4. Weather-Driven — Estacional

Basada en los patrones de la Sección 11:

- **Cacao**: largo abril–junio (post-sequía); corto octubre–diciembre (cosecha)
- **Gas TTF**: largo octubre–febrero (calefacción); corto abril–agosto (inyección)
- **Uranio**: posición plana (sin driver estacional)

12.2.5. Vol Breakout

Largo cuando el precio rompe por encima del máximo de 20 días más 1,5 veces el ATR. Captura rupturas de rangos de consolidación.

12.2.6. Combinada — Ensemble de igual peso

$$\text{Señal}_t^{\text{comb}} = \text{clip}\left(\frac{1}{5}\sum_{i=1}^{5}\text{Señal}_t^{(i)},\ -1,\ +1\right) \tag{40}$$

Media igual de las cinco estrategias. La diversificación entre señales no correlacionadas reduce el drawdown manteniendo retornos positivos.

12.3. Métricas de rendimiento

Métrica	Fórmula	Qué mide
Retorno anualizado	$\bar{r} \times 252$	Rentabilidad media anual
Ratio de Sharpe	$(\bar{r} - r_f)/\sigma \times \sqrt{252}$	Retorno por unidad de riesgo total
Ratio de Sortino	$(\bar{r} - r_f)/\sigma_{\downarrow} \times \sqrt{252}$	Retorno por riesgo bajista
Max Drawdown	Caída máxima desde pico	Peor pérdida posible
Ratio de Calmar	Ret. anual / |Max DD|	Retorno relativo a la peor pérdida
Win Rate	% de días con retorno positivo	Consistencia de la estrategia

Table 9: Métricas de rendimiento del motor de backtesting

12.4. Resultados empíricos: Gas Natural TTF

El resultado más llamativo es que **Mean Reversion es la mejor estrategia para el Gas TTF**, con Sharpe de 0,56 y retorno total de +47% en dos años, mientras el benchmark de comprar y mantener está en terreno negativo.

Esto es económicamente intuitivo: los precios del gas exhiben fuerte reversión a la media porque la oferta (GNL, almacenes) responde con relativa rapidez a los spikes. Las estrategias de tendencia pierden dinero porque persiguen rallies que se revierten.

Conclusión: la estrategia óptima depende de la microestructura del commodity. Commodities con reversión a la media (gas, electricidad) favorecen estrategias contrarias. Commodities con shocks de oferta estructurales (cacao 2023–24) pueden favorecer trend following.

12.5. Advertencias

A1. Calidad de datos: precios de proxies ETF, no cadenas de futuros reales. Costes de roll y riesgo de base no capturados.

A2. Riesgo de sobreajuste: 2 años y 5 estrategias no son suficientes para inferencia estadísticamente robusta. Se recomiendan > 10 años y > 200 operaciones.

A3. Impacto de mercado: ejecución asumida al cierre con coste fijo. En commodities ilíquidos los costes reales son significativamente mayores.

A4. Cambios de régimen: la crisis de 2022–23 es una ruptura estructural. Las estrategias calibradas en datos post-crisis pueden no generalizarse.

[1] Artzner, P., Delbaen, F., Eber, J.-M. y Heath, D. (1999). Medidas coherentes de riesgo. *Mathematical Finance*, 9(3), 203–228.

[2] Black, F. (1976). La valoración de contratos sobre materias primas. *Journal of Financial Economics*, 3(1–2), 167–179.

[3] Fama, E. y French, K. (1987). Precios de futuros sobre materias primas. *Journal of Business*, 60(1), 55–73.

[4] Hagan, P., Kumar, D., Lesniewski, A. y Woodward, D. (2002). Gestión del riesgo de smile. *Wilmott Magazine*, septiembre, 84–108.

[5] Kalman, R.E. (1960). Un nuevo enfoque para el filtrado lineal y la predicción. *Journal of Basic Engineering*, 82(1), 35–45.

[6] Schwartz, E.S. (1997). El comportamiento estocástico de los precios de las materias primas. *Journal of Finance*, 52(3), 923–973.

[7] Schwartz, E.S. y Smith, J.E. (2000). Variaciones de corto plazo y dinámica de largo plazo en los precios de las materias primas. *Management Science*, 46(7), 893–911.

[8] Working, H. (1949). La teoría del precio del almacenamiento. *American Economic Review*, 39(6), 1254–1262.